

OBSERVABILIDAD CON OPENTELEMETRY

SISTEMA DE DIAGNÓSTICO EMPRESARIAL PARA DETECCIÓN DE ERRORES Y LATENCIAS

1. ¿Por que implementar OpenTelemetry (OTel)?

En un sistema distribuido que integra multiples sistemas externos (como la API de precios de CoinGecko y el motor de IA de Google Gemini 3.5), la observabilidad es vital. El estandar OpenTelemetry nos permite rastrear con precision de milisegundos que paso con una consulta, en que momento ocurrio y, en caso de fallas, determinar la causa raiz de forma automatica y cientifica, evitando conjeturas.

2. Los Pilares de la Observabilidad Implementados

- Pilar 1: Monitoreo por Spans (Trazabilidad)

Creamos spans aislados para auditar de forma independiente cada capa del sistema: 'get_asset_price' para el conector, 'simulate_transaction' para el adaptador y 'run_query' para el motor de Gemini. Esto aísla y visualiza los cuellos de botella de red de inmediato.

- Pilar 2: Correlacion de Logs (Trace ID & Span ID)

Inyectamos de forma dinamica el TraceId y SpanId unico de OpenTelemetry dentro del formateador de logs de FastAPI. De este modo, si se procesan 10,000 peticiones en paralelo, podemos rastrear y filtrar todas las lineas de log de un usuario especifico con un solo clic.

- Pilar 3: Registro y Deteccion de Fallas (Error Handling)

Si un sistema externo falla (como el rate-limit 429 de Gemini o errores 404 de CoinGecko), el Span correspondiente se marca automaticamente con estatus 'ERROR' y adjunta metadatos del error. El middleware previene la caida del sistema y activa el fallback de manera segura.

3. Ejemplo de Trazas impresas en Consola

```

[OTel Span] 'get_asset_price' | Parent: 0x93ef... | Status: StatusCode.OK | Duration: 15.42ms
[OTel Span] 'simulate_transaction' | Parent: 0xbfd7... | Status: StatusCode.OK | Duration: 23.10ms
[OTel Span] 'run_query' | Parent: 0x00f0... | Status: StatusCode.OK | Duration: 1120.40ms
  
```

4. Como Demostrar la Observabilidad en Vivo

- Demostracion 1 (Desglose de Spans): Al realizar una consulta, la consola de FastAPI imprimira automaticamente las duraciones parciales de cada capa en formato OTel Span, visualizando la rapidez de tus de algoritmos locales.
- Demostracion 2 (Correlacion): Muestra las lineas de log del servidor. Resalta que cada registro posee la cabecera correlacionada [TraceId: ... | SpanId: ...] inyectada por tu middleware de OTel.
- Demostracion 3 (Errores): Ejecuta una llamada con un activo inexistente (como 'XYZ') y observa como el Span se marca con estado 'ERROR' capturando la excepcion de forma autonoma sin que caiga la API.
- Demostracion 4 (Fallo de BD): Bloquea 'mock_db.json' como 'Solo Lectura'. Observa cómo OTel registra la excepción de disco 'PermissionError' y el adaptador aborta la llamada a Gemini, previniendo inconsistencias.