

PASO 7: OBSERVABILIDAD DE LLM OPS EN LA NUBE

INTEGRACIÓN PASO A PASO CON LANGFUSE CLOUD (MARCELO GILARDONI)

Estudiante: Marcelo Gilardoni

Usuario de GitHub: gilardoni72

Este manual describe los 4 pasos exactos de ejecución e indicaciones técnicas para realizar la prueba de Observabilidad Cognitiva en la nube con Langfuse Cloud durante tu sustentación. Permite auditar costos en USD, tokens, prompts e identidades enmascaradas frente al docente.

Requisito Previo obligatorio: Enlace de Credenciales

Para que tu servidor FastAPI local se comunique de forma segura con la nube de Langfuse:

1. Inicia sesión en us.cloud.langfuse.com y ve a Settings -> API Credentials.
2. Crea nuevas llaves y guardalas de forma local en tu archivo 'codigo/.env' (ignorado por Git):


```
LANGFUSE_PUBLIC_KEY="pk-lf-..."
LANGFUSE_SECRET_KEY="sk-lf-..."
LANGFUSE_HOST="https://us.cloud.langfuse.com"
```

Secuencia de Ejecución en Vivo (4 Pasos)

Paso 1: Crear el Dataset de 20 casos de prueba en la Nube

¿Qué es un Dataset en Langfuse?

Un dataset es una colección estructurada de registros de prueba (consultas reales de entrada de los usuarios) emparejadas con sus resultados esperados de referencia (SLA o Expected Output). Funciona como la plantilla de calibración oficial (el 'patrón oro') para auditar el comportamiento de Gemini 3.5 de forma automatizada.

¿Cómo fue que lo creamos?

1. Diseñamos localmente un archivo estructurado en formato JSON Lines llamado 'casos_ejemplo_trading.jsonl' conteniendo 20 casos reales balanceados (50% positivos y 50% negativos para estresar las fallas).
2. Desarrollamos el script en Python 'create_langfuse_dataset.py' que lee ese archivo local línea por línea y sube los 20 casos al dataset 'trading_agent_evaluation' en la nube usando el método 'create_dataset_item()'.

Comando literal para ejecutar en PowerShell:

```
python codigo/scripts/create_langfuse_dataset.py
```

- Qué señalar: Actualiza tu navegador en la pestaña 'Datasets' y enseña tu dataset creado con los 20 casos cargados.

Paso 2: Ejecutar la Corrida de Evaluación en Vivo (con Gemini 3.5)

¿Qué hace este script técnicamente?

1. Descarga dinámicamente los 20 items del dataset desde la nube de Langfuse usando 'get_dataset()'.
2. Procesa cada caso en tu agente, el cual sanitiza el nombre (PII) e implementa la transaccionalidad SRE conmutando de forma segura al simulador offline local en milisegundos si la API Key está bloqueada.
3. Vinculación Asociativa: Llama al método 'create_dataset_run_item()' para asociar de forma inalterable la traza con su correspondiente item en el Dataset de Langfuse. Al finalizar, ejecuta un vaciado asíncrono 'langfuse.flush()' para garantizar la subida del 100% de los datos.

Comando literal para ejecutar en PowerShell:

```
python codigo/scripts/run_langfuse_evaluation.py
```

- Qué señalar: Tu agente evaluará los 20 casos, enmascarará las identidades y enviará todas las métricas y comparativas de respuestas de forma automática a la nube de Langfuse.

Paso 3: Mostrar las Trazas Individuales (Tracing)

Ve a la pestaña 'Tracing' en tu navegador de Langfuse y selecciona una consulta exitosa:

- Enmascaramiento: Señala que el User ID registrado es 'M**** G****', protegiendo la privacidad (PII).
- Costos y Tokens: Señala en la tarjeta 'Model costs' el costo calculado en USD y los tokens consumidos.

Paso 4: El Dashboard Ejecutivo Consolidado (Métricas de Gerencia)

Haz clic en la pestaña 'Dashboards' o 'Home' en Langfuse Cloud:

- Enseña los graficos interactivos auto-generados que consolidan tu uso de Gemini 3.5:
 - * Model Cost (Costos totales acumulados en dolares).
 - * Total Traces (Volumen total de transacciones simuladas).
 - * Model Usage (Distribucion de tokens y llamadas por modelo).
 - * Latency averages (Historia de velocidad y rendimiento de tu API).

Guía de Observabilidad en la Nube - Marcelo Gilardoni | Solutions Architect & SRE.