

PASO 7: OBSERVABILIDAD DE LLM OPS EN LA NUBE

INTEGRACIÓN PASO A PASO CON LANGFUSE CLOUD (MARCELO GILARDONI)

Estudiante: Marcelo Gilardoni

Usuario de GitHub: gilardoni72

Este manual describe los 4 pasos exactos de ejecución e indicaciones técnicas para realizar la prueba de Observabilidad Cognitiva en la nube con Langfuse Cloud durante tu sustentación. Permite auditar costos en USD, tokens, prompts e identidades enmascaradas frente al docente.

Requisito Previo obligatorio: Enlace de Credenciales

Para que tu servidor FastAPI local se comunique de forma segura con la nube de Langfuse:

1. Inicia sesión en us.cloud.langfuse.com y ve a Settings -> API Credentials.
2. Crea nuevas llaves y guardalas de forma local en tu archivo '.env' (ignorado por Git):
LANGFUSE_PUBLIC_KEY="pk-lf-..."
LANGFUSE_SECRET_KEY="sk-lf-..."
LANGFUSE_HOST="https://us.cloud.langfuse.com"

Secuencia de Ejecución en Vivo (4 Pasos)

Paso 1: Crear el Dataset de 20 casos de prueba en la Nube

Ejecuta en PowerShell el script poblador de datasets:

Comando: `python codigo/scripts/create_langfuse_dataset.py`

- Que señalar: En el navegador, actualiza y muestra en la pestaña 'Datasets' el dataset 'trading_agent_evaluation' con tus 20 casos de prueba creados de forma instantánea.

Paso 2: Ejecutar la Corrida de Evaluación en Vivo (con Gemini 3.5)

Ejecuta en PowerShell la evaluación cognitiva automática de los 20 casos:

Comando: `python codigo/scripts/run_langfuse_evaluation.py`

- Que señalar: Tu agente procesará cada caso de forma real, enmascarará las identidades a M**** G**** y enviará las métricas de trazas, costos y respuestas a Langfuse Cloud.

Paso 3: Mostrar las Trazas Individuales (Tracing)

Ve a la pestaña 'Tracing' en tu navegador de Langfuse y selecciona una consulta exitosa:

- Enmascaramiento: Señala que el User ID registrado es 'M**** G****', protegiendo la privacidad (PII).
- Costos y Tokens: Señala en la tarjeta 'Model costs' el costo calculado en USD y los tokens consumidos.

Paso 4: El Dashboard Ejecutivo Consolidado (Métricas de Gerencia)

Haz clic en la pestaña 'Dashboards' o 'Home' en Langfuse Cloud:

- Enseña los gráficos interactivos auto-generados que consolidan tu uso de Gemini 3.5:
 - * Model Cost (Costos totales acumulados en dólares).
 - * Total Traces (Volumen total de transacciones simuladas).
 - * Model Usage (Distribución de tokens y llamadas por modelo).
 - * Latency averages (Historia de velocidad y rendimiento de tu API).